

Benchmark de detección con Mímir real

15 videos, 4 conceptos (violencia, robos, caídas, cuchillo), Amazon Nova Lite vía Bedrock conectado de verdad. Corrido el 17 de septiembre de 2026.

Resumen ejecutivo

De los 11 videos con un evento real, el sistema confirmó 6 (55%) y nunca generó una falsa alarma en los 4 videos de control (negativos genuinos o casos donde no debía alertar). **Persona** y **caídas** funcionan de forma consistente; **violencia** funciona en 3 de 4 casos; **robos** es el punto débil real, con 0 de 3 confirmaciones a pesar de que la Capa 1 (CLIP) sí distinguía el evento en los tres. Costo total real: **USD 0.008** (109 llamadas a Mímir). Tiempo total: ~90 minutos.

Cómo funciona el pipeline: qué hace cada capa

Un frame pasa por tres capas en orden. Cada una solo entra en acción sobre lo que le dejó pasar la anterior -- ninguna ve el video completo de una.

● Capa 0 -- Movimiento (vision.py, clase MotionDetector)

Entra primero, en TODO frame, sin excepción (evaluar_video_v3.py línea 143). Resta el fondo (MOG2) y propone recuadros (ROIs) donde hubo movimiento real. Si no encuentra ninguno, el frame se descarta ahí mismo -- columna "Sin movim." de la tabla de trazabilidad -- sin gastar CLIP ni Mímir.

● Capa 1 -- CLIP (vision.py, clase ClipScorer)

Entra solo sobre los recortes que dejó pasar la Capa 0 -- nunca ve el frame completo. Puntúa cada recorte contra los prompts del concepto (ej. "a person fallen on the floor") con margen contrastivo. Si el score no llega al umbral, se descarta ("Mov+CLIP bajo"); si lo supera, la decisión pasa a "ambiguous" (eventos abstractos) o "clear" directo (conceptos concretos con margen alto, ej. persona).

● Capa 2 -- Mímir (vlm.py, Nova Lite vía Bedrock)

Entra SOLO cuando la decisión queda en "ambiguous" -- es la más cara, por eso las dos capas anteriores ya filtraron todo lo que se pudo filtrar gratis. Recibe una ráfaga de 4 frames (1.5s de historia, no un solo instante) y responde SI/NO a una pregunta específica del concepto. Su respuesta decide si el evento se confirma ("clear") o se descarta ("none").

Resultado por video

Video	Concepto	AUC	Latencia	Detectó	Llam. VLM
Fighting003_x264A.mp4	violencia	0.5342	27.97s	Sí	17
Shooting002_x264A.mp4	violencia	0.7618	2.00s	Sí	7
Assault011_x264.mp4	violencia	0.4622	n/a	No	13

Video	Concepto	AUC	Latencia	Detectó	Llam. VLM
Fighting042_x264A.mp4	violencia	0.6673	15.30s	Sí	11
Normal_Videos_015.mp4	violencia (negativo)	n/a	n/a	No (correcto)	2
Fighting042_x264A.mp4	persona	n/a	n/a	Sí	11
Normal_Videos_015.mp4	persona	n/a	n/a	Sí	2
Robbery048_x264.mp4	robos	0.7558	n/a	No	7
Robbery102_x264.mp4	robos	0.6123	n/a	No	8
Burglary024_x264A.mp4	robos	0.7677	n/a	No	6
Normal_Videos_015.mp4	robos (negativo)	n/a	n/a	No (correcto)	2
caida_escaleras.mp4	caidas	0.6693	7.92s	Sí	10
caida_judo_src.webm	caidas (negativo difícil)	n/a	n/a	No (correcto)	2
cuchillo_afilado.mp4	cuchillo	n/a	n/a	No	2
cuchillo_piedra.mp4	cuchillo	n/a	n/a	Sí	3

AUC/latencia salen "n/a" cuando el video no tiene un tramo negativo comparable dentro del mismo clip (negativos puros, o el objeto/persona presente en todo el video) -- no es un cálculo que falló.

Hallazgos por concepto

● *persona* — *Funciona de forma muy consistente*

13 de 13 llamadas confirmaron correctamente, en dos videos distintos. Es el concepto más confiable de los cuatro.

● *caidas* — *Funciona bien, incluyendo un caso límite*

Confirmó la caída real en escaleras (AUC 0.6693, latencia 7.92s) y rechazó correctamente un lanzamiento de judo controlado -- reconociendo por sí solo que era "una posición de lucha controlada", sin que la pregunta se lo pidiera explícitamente.



caida_escaleras -- confirmado (Sí).



caida_judo -- rechazado a propósito (No, correcto).

● *violencia* — *Funciona cuando el golpe es visualmente claro*

3 de 4 videos con evento real confirmaron, con 0 falsos positivos. El único que falló (Assault011) no fue por Mimir: CLIP (Capa 1) nunca encontró señal de violencia en ese video en particular, ni dentro ni fuera del evento -- es un caso sin señal, no un caso difícil.



Assault011 -- el frame con el score de CLIP más alto de TODO el video (fuera del evento real): una vara en la mano generó más señal que la propia agresión.

● **robos — El punto débil real -- 0 de 3 confirmó**

Se probaron tres tipos distintos de robo (arma oculta/pequeña, forcejeo sin despojo visible, hurto silencioso sin fuerza) y ninguno confirmó, a pesar de que CLIP sí distinguía el evento en los tres (AUC 0.61-0.77). El cuello de botella está en Mimir: necesita ver fuerza, despojo o forcejeo claro, evidencia que estos tres robos reales no mostraban en los frames muestreados.



Robbery048 -- arma apuntada, pero muy pequeña/oculta para confirmar.



Robbery102 -- forcejeo claro, pero sin el momento del despojo.



Burglary024 -- hurto silencioso, indistinguible de un empleado trabajando.

● **cuchillo — Depende de si el objeto está oculto**

Falló cuando la mano tapaba el cuchillo contra la piedra de afilar, y confirmó (2 de 3 llamadas) con el mismo tipo de objeto claramente visible en otro video -- confirmando que el problema es la oclusión, no la resolución ni el tamaño del objeto en sí.



cuchillo_afilado -- la mano tapa la hoja (No).



cuchillo_piedra -- la hoja queda visible (Sí).

Opciones de mejora identificadas

Ráfaga más larga para robos. Un robo silencioso es un evento sostenido, no instantáneo. Probar 8 frames en 4-5s (en vez de 4 frames en 1.5s) solo para este concepto, sin costo adicional real por llamada.

Usar la hora quemada en el video. Varios videos de vigilancia traen fecha/hora sobreimpresa en la imagen. Pedirle a Mimir que la lea y considere si es una hora inusual para la actividad observada le da contexto que hoy no tiene.

Detector de manos + zoom (cuchillo/armas ocultas). Usar el detector de pose (yolo_gate.py, hoy en experimental/) para ubicar las manos y recortar/ampliar esa región antes de mandarla a Mimir. Requiere más trabajo de implementación que las dos anteriores.

Costo total de esta corrida: USD 0.008 (109 llamadas reales a Mimir, \$0.000076 cada una). Tiempo total: ~90 minutos, corrido en 5 tramos para esquivar el vencimiento de la sesión de credenciales AWS. Reporte generado por la Suite Manual de Heimdall (correr_suite.py) -- fase 1 de la automatización propuesta, sin GitHub Actions ni infraestructura nueva todavía.

Prueba visual: la Capa 0 (Movimiento) sí recorta de verdad

MotionDetector.rois() (vision.py, idéntico al repo real salvo el fix de MIN_MOTION_AREA) corrió sobre Fighting042_x264A.mp4. Los recuadros rojos son los ROIs reales que produjo -- exactamente lo que después se recorta y se manda a CLIP, no una simulación aparte.



Frame 300 -- 2 ROIs, siguiendo a la persona que camina.



Frame 450 -- 2 ROIs, sobre el forcejeo en la puerta.



Frame 850 -- 5 ROIs, el momento más caótico de la escena.

Esta es la misma línea de código (evaluar_video_v3.py, línea 143: `rois = motion.rois(frame)`) que corrió, sin excepción, en cada frame de los 15 videos del reporte -- no es una demostración aparte.

Trazabilidad por capa: dónde se descarta cada frame

Cada fila de los CSV de resultado permite separar cuántos frames se descartaron por **falta de movimiento** (Capa 0, score=0.0 porque MotionDetector.rois() no encontró nada) de cuántos tuvieron movimiento pero CLIP los descartó igual (Capa 1, score por debajo del umbral). Es la prueba de que ambas capas están filtrando de verdad, no solo la última.

Video / concepto	Sin movim.	Mov+CLIP bajo	Ambiguous	Clear
Assault011 x264 violencia	37	16	2067	0
Burglary024 x264A robos	637	10	384	0
Fighting003 x264A violencia	121	16	2468	3
Fighting042 x264A persona	168	5	1354	11
Fighting042 x264A violencia	168	21	1320	1
Normal Videos 015 x264 persona	42	0	264	2
Normal Videos 015 x264 robos	42	3	262	0
Normal Videos 015 x264 violencia	42	5	248	0
Robbery048 x264 robos	128	21	689	0
Robbery102 x264 robos	239	13	596	0
Shooting002 x264A violencia	22	9	1074	2
caida escaleras caidas	16	42	1209	3
caida judo src caidas	9	7	140	0
cuchillo afilado cuchillo	72	17	22	0
cuchillo piedra cuchillo	3	8	488	2

"Sin movimiento" y "con movimiento, CLIP bajo" juntos forman el total de "none" del reporte anterior -- aquí se separan para mostrar que la Capa 0 (movimiento) descarta una porción real y distinta en cada video (desde 3 frames en cuchillo_piedra hasta 637 en Burglary024), no un número fijo o simulado.